

Fundamentos y modelos clásicos de aprendizaje automático aplicados a fraude

**Informe para la actividad 1 de la asignatura:
Aprendizaje automático**

Presentado por: Omar Javier Daza Leguizamón



Fundación Universitaria Internacional de La Rioja

Especialización en Inteligencia Artificial

Agosto de 2026

Contenido

1.	Introducción.....	3
2.	Descripción general del <i>dataset</i> y aspectos metodológicos preliminares.....	3
3.	Análisis descriptivo y preparación de datos.....	5
3.1	Estadísticos descriptivos para las variables numéricas	5
3.2	Frecuencias para las variables categóricas.....	6
3.3	Matriz de correlaciones	7
3.4	Tratamiento de valores faltantes y datos atípicos	9
4.	Agrupamiento mediante K-means	9
4.1	Solución con tres grupos	10
4.2	Solución con dos grupos	11
4.3	Ventajas y desventajas de la técnica de agrupamiento.....	11
5.	Detección de anomalías.....	12
6.	Protocolo experimental de la parte 2 de la actividad	13
7.	Laboratorio de regresión.....	14
7.1	Análisis de los resultados para las métricas.....	14
7.2	Interpretación de los coeficientes para el modelo completo	15
7.3	Análisis de residuos y limitaciones	15
8.	Naive Bayes	16
8.1	Matriz de confusión y curva ROC.....	16
8.2	Análisis del supuesto de independencia del método.....	17
8.3	Algunas reflexiones sobre los sesgos del algoritmo y las implicaciones éticas	18
9.	Interpretabilidad y explicabilidad	18
9.1	Estructura del árbol.....	19
9.2	Aplicación de SHAP e influencia de las variables	20
10.	Random Forest y flujo de MLOps	21
11.	Boosting moderno y máquinas de vector soporte (SVM)	22
12.	Comparación de los modelos	24
13.	Integración, limitaciones y panorama actual	25
14.	Anexo	27
15.	Referencias bibliográficas	27

1. Introducción

La inteligencia artificial, a través de las técnicas y métodos del aprendizaje automático, se ha convertido en las últimas décadas en un elemento importante para la toma de decisiones en muchos campos relacionados con nuestra vida diaria. El aprendizaje automático, también conocido como *Machine Learning*, se ha incorporado de forma progresiva en áreas como la salud, las finanzas, la educación, el transporte y los servicios públicos, aportando capacidades de procesamiento y análisis de grandes volúmenes de datos. Entre las grandes ventajas del uso de estos métodos están la reducción de los tiempos de análisis, la optimización de recursos y la toma de decisiones basadas en datos ajustadas a contextos específicos. Esta creciente influencia del *Machine Learning* ha llevado a que pase de ser de uso exclusivo de expertos y científicos a convertirse en una herramienta de uso masivo en diversos campos aplicados.

Este documento presenta una de las aplicaciones más comunes de las técnicas del aprendizaje automático. El fraude con tarjetas de crédito implica la toma de decisiones en las entidades financieras para identificar los casos en los que se genera una alerta, teniendo presente que cualquier error de identificación puede generar problemas para la entidad o para el usuario. Cuando el sistema deja pasar una transacción fraudulenta, la entidad puede asumir una pérdida directa; por el contrario, si se bloquea una tarjeta cuando la operación es legítima, se afecta directamente al cliente. Este tipo de decisiones implica grandes volúmenes de datos que deben analizarse para minimizar los errores de detección.

Se analiza un conjunto de datos generado sintéticamente con diferentes técnicas de aprendizaje profundo, entre ellas el agrupamiento, la detección de anomalías, la regresión lineal, *Naive Bayes*, árboles de decisión, *random forest*, *gradient boosting* y máquinas de vectores de soporte; se comparan bajo condiciones idénticas y se discuten sus implicaciones prácticas y éticas. Este análisis forma parte de un ejercicio académico sobre la aplicación de técnicas de aprendizaje profundo y presenta los principales procedimientos, los resultados de los análisis y las conclusiones obtenidas para cada método.

2. Descripción general del *dataset* y aspectos metodológicos preliminares

El conjunto de datos se obtuvo de un repositorio público a través del siguiente enlace: <https://www.kaggle.com/shubhamjoshi2130of/abstract-data-set-for-credit-card-fraud-detection>. La primera revisión de los datos no permite identificar su fuente y el sitio web estima su completitud en un 25%, su credibilidad en un 33% y su compatibilidad en un 50%. Estas características, junto con la falta de metadatos, hicieron suponer que los datos fueron generados sintéticamente con fines, tal vez, académicos. Esta suposición se confirma más adelante, durante el análisis, mediante los modelos mencionados anteriormente. Por otro lado, al analizar visualmente los datos, se entiende que cada fila del archivo no corresponde a un titular de la tarjeta, sino que está asociada a una transacción en el comercio. Las variables relacionadas con los promedios de gasto, los contracargos y los rechazos describen el historial del establecimiento y no el del cliente.

En la siguiente tabla se presenta la interpretación de las variables del *dataset*.

Tabla 1. Variables del conjunto de datos

Variable	Tipo	Significado
Merchant_id	Identificador	Código del comercio. No se emplea como predictor.
Transaction date	Desconocido	Fecha de la operación. Vacía en el 100 % de los registros.
Average Amount/ transaction/day	Continua	Importe promedio por transacción diaria del comercio. Define su comportamiento habitual.
Transaction_amount	Continua	Importe de la transacción que se evalúa.
Is declined	Categórica Y/N	Indica si la operación fue rechazada por el banco emisor.
Total Number of declines/day	Discreta	Rechazos acumulados en la jornada. Muchos rechazos seguidos son el patrón típico del ensayo sistemático de tarjetas robadas.
isForeignTransaction	Categórica Y/N	Operación transfronteriza.
isHighRiskCountry	Categórica Y/N	País incluido en una lista de alto riesgo de fraude.
Daily_chargeback_avg_amt	Continua	Importe medio diario de contracargos del comercio.
6_month_avg_chbk_amt	Continua	Importe medio de contracargos en seis meses.
6-month_chbk_freq	Discreta	Número de contracargos en seis meses.
isFradulent	Categórica Y/N	Variable objetivo.

El abordaje de la aplicación de los métodos de aprendizaje profundo sobre el conjunto de datos se hizo bajo las siguientes consideraciones metodológicas:

- Durante el desarrollo de la actividad académica se utilizaron técnicas de aprendizaje supervisado y no supervisado. Para este segundo grupo, la etiqueta de fraude se utiliza exclusivamente para evaluar la calidad del resultado, nunca para construirlo.
- Los datos se dividen mediante la técnica de *hold-out*, para tener un 80% que se utiliza para el entrenamiento y un 20% reservado para la evaluación final. La partición se realizó de forma estratificada, manteniendo prácticamente igual la proporción de fraude en ambos subconjuntos. Esta decisión se toma para que las diferencias observadas sean una consecuencia del algoritmo y no del efecto de variaciones en los datos de evaluación.
- Las métricas de evaluación se resumen en la siguiente tabla.

Tabla 2. Métricas de evaluación

Métrica	¿Qué mide?
Exactitud	Proporción de aciertos respecto del total.
Precisión	De las transacciones señaladas como fraude, ¿cuántas lo eran realmente?
<i>Recall</i>	De los fraudes existentes, ¿cuántos detecta el modelo?
F1	Combinación equilibrada de precisión y <i>recall</i> (media armónica).
ROC-AUC	Capacidad para ordenar las transacciones por riesgo, independientemente del umbral elegido.
PR-AUC	Variante de la anterior, más exigente cuando la clase de interés es minoritaria.

3. Análisis descriptivo y preparación de datos

3.1 Estadísticos descriptivos para las variables numéricas

El resumen estadístico muestra distribuciones muy dispares. La medida considerada de mayor relevancia es la asimetría, la cual indica si los valores se distribuyen de forma equilibrada alrededor de la media o si se concentran en un extremo, con una cola larga hacia el otro.

Tabla 3. Estadísticos descriptivos de las variables numéricas

Variable	Media	Mediana	Máximo	Asimetría
Average Amount/transaction/day	515	474	2000	0,18
Transaction_amount	9876	6600	108000	2,11
Total Number of declines/day	1,02	0	20	2,69
Daily_chargeback_avg_amt	31,5	0	998	3,53
6_month_avg_chbk_amt	24,6	0	998	3,72
6-month_chbk_freq	0,26	0	9	4,05




Imagen 1. Distribución de las variables numéricas

El importe promedio diario presenta una distribución aproximadamente simétrica, mientras que las restantes variables están fuertemente sesgadas. El importe de la transacción tiene un máximo

de 108000 y una mediana de 6600, lo que indica que unas pocas operaciones de cuantía muy elevada estiran la distribución. Las variables de contracargo y de rechazos, por su parte, se concentran masivamente en el valor cero. Estas asimetrías justifican dos decisiones metodológicas: el cálculo de un coeficiente de correlación alternativo y la transformación de variables antes de aplicar el modelo de detección de anomalías.

3.2 Frecuencias para las variables categóricas

Las cuatro variables categóricas son dicotómicas (Y/N), con distribuciones desiguales y magnitudes distintas.

Tabla 4. Frecuencias de las variables categóricas

Variable	N (no)	Y (sí)	Interpretación
Is declined	98,15 %	1,85 %	El rechazo directo es un evento excepcional.
isForeignTransaction	77,04 %	22,96 %	Casi una de cada cuatro operaciones es internacional.
isHighRiskCountry	93,33 %	6,67 %	Solo 205 transacciones provienen de países de alto riesgo.
isFradulent	85,43 %	14,57 %	448 fraudes frente a 2.627 operaciones legítimas.




Imagen 2. Distribución de variables categóricas

Los fraudes representan el 14,6% de los registros, por lo que la exactitud deja de ser un criterio válido, ya que un sistema que simplemente respondiera «no hay fraude» ante cualquier transacción acertaría el 85,4% de las veces sin haber detectado un solo caso. Por este motivo, la evaluación posterior prioriza el *recall* y el F1. En escenarios reales de fraude, la clase positiva suele representar

menos del 1 % de las operaciones (el conjunto de referencia europeo más utilizado en la literatura contiene un 0,172 % de fraude (Dal Pozzolo et al., 2015)), de modo que el 14,6 % de este archivo constituye un desbalance moderado, dos órdenes de magnitud por encima de lo habitual.

Las cuatro variables dicotómicas, almacenadas en texto, quedarían excluidas de cualquier cálculo numérico. Declararlas explícitamente como binarias las incorpora al análisis y permite su procesamiento por las bibliotecas de modelado.

3.3 Matriz de correlaciones

La correlación mide el grado en que dos variables varían conjuntamente (en una escala de -1 a $+1$). Para incluir las variables categóricas en el cálculo fue necesario codificarlas como 0 y 1. Aclarando que, al aplicarlo a variables dicotómicas, el coeficiente de Pearson coincide matemáticamente con el llamado coeficiente phi (Newsom, 2025), de modo que su interpretación como medida de asociación sigue siendo válida. Por otro lado, dado que en el apartado 3.1 se identificaron distribuciones asimétricas en la mayoría de las variables, además del coeficiente de Pearson, se calculó el coeficiente de Spearman, ya que este es más robusto para distribuciones de este tipo.




Imagen 3. Matriz de correlaciones – Pearson

La lectura de la matriz de correlación con Pearson permite establecer los siguientes puntos, con relación a la variable objetivo:

- La variable que indica la procedencia de un país de alto riesgo presenta la asociación más alta, con un coeficiente de correlación de 0,640. Al realizar un examen detallado, se revela una relación casi determinista: de las 205 transacciones con ese origen, 203 son fraudulentas, lo que representa el 99,0 %. Este dato servirá de base para la reflexión ética del numeral 8.5.
- El número de rechazos diarios ($R=0,532$) y el importe de la operación ($R=0,529$) muestran el efecto de los intentos repetidos y de los importes elevados. El importe medio en fraude asciende a 22.855 frente a 7.663 en las transacciones legítimas.
- Las tres variables relacionadas con los contracargos se asocian moderadamente con el fraude (valores entre 0,376 y 0,444), pero entre sí están casi solapadas, lo cual se evidencia al observar que la correlación entre el promedio diario y el semestral alcanza 0,954.
- El importe promedio diario del comercio presenta una correlación de tan solo 0,024 con la variable objetivo, a pesar de tener un valor de 0,587 con el importe de la transacción. Esto implica que esta variable no informa sobre el nivel absoluto del gasto habitual, sino sobre cuánto se desvía de dicho nivel la operación evaluada.




Imagen 4. Matriz de correlaciones - Spearman

Por otro lado, al contrastar los dos coeficientes (Pearson vs Spearman) se encuentran dos discrepancias de relevancia. Primero, la asociación entre el importe y el fraude cae de 0,529 a 0,398 al trabajar con rangos; esto indica que el coeficiente lineal está sesgado por unas pocas operaciones de cuantía extrema. Segundo, la redundancia entre las variables de contracargo se intensifica hasta alcanzar 0,998, lo que confirma que los registros se ordenan de manera casi idéntica. Debe notarse que el elevado número de empates (el 92,9% de los registros presenta un contracargo nulo) condiciona parcialmente esta última medida.

3.4 Tratamiento de valores faltantes y datos atípicos

El diagnóstico de la completitud de los datos permitió identificar un único caso de valores ausentes: la variable de fecha está vacía en la totalidad de los registros. Por lo tanto, se tomó la decisión de eliminarla del *dataset*. Ninguna otra variable presenta valores ausentes; en consecuencia, no se elimina ningún registro y se conserva la totalidad de la muestra. Además, las tres variables de contracargo presentan un 92,9% de ceros y la de rechazos un 77,5%, pero estos no son datos ausentes. Estos valores representan una situación normal de un comercio sin incidencias registradas. Tratarlos como datos ausentes introduciría un historial de fraude inexistente en el 93% de los comercios.

En cuanto a los datos atípicos, el procedimiento para identificarlos consiste en clasificarlos como tales cuando se alejan más de 1,5 veces del rango intercuartílico entre los cuartiles primero y tercero. La aplicación de este criterio en este caso no es coherente con la interpretación de la situación y los datos asociados. La mayoría de las observaciones se concentran en cero, los cuartiles primero y tercero coinciden en cero y el recorrido intercuartílico se anula. Esto implica que cualquier valor distinto de cero quedaría clasificado como un dato atípico. Por lo tanto, eliminar los 691 registros señalados en la variable de rechazos eliminaría las observaciones que contienen la señal de fraude. Esto lleva a concluir que no se eliminan estos «valores atípicos» por considerarse que aportan información y no constituyen errores en el *dataset*.

4. Agrupamiento mediante K-means

El agrupamiento, o *clustering*, divide las observaciones en grupos homogéneos sin conocer previamente la respuesta correcta. El algoritmo *K-means* divide los datos en k grupos, minimizando la suma de las distancias de cada observación a su centroide correspondiente. Este procedimiento es iterativo: empieza por asignar cada punto al centroide más próximo, continúa recalculando los centroides como el promedio de los puntos asignados y, finalmente, se repite hasta estabilizarse (James, G., Witten, D., Hastie, T. y Tibshirani, R., 2021). Considerando que *K-means* se basa en distancias, las variables con recorridos amplios dominan el cálculo; se aplicó una estandarización que sitúa todas las variables en media cero y una desviación estándar de 1.

Se evaluaron tres criterios para seleccionar el valor de k ; cada uno de ellos se calculó para valores de k entre 2 y 8. En la siguiente tabla se presentan los métodos y los valores calculados.

Tabla 5. Índices internos de calidad del agrupamiento

k	Inercia	Silueta	Davies-Bouldin
2	18.611	0,661	0,938
3	14.635	0,556	1,028
4	12.261	0,327	1,120
5	9.952	0,342	1,067
6	8.176	0,406	0,961

Los valores de los índices orientan la decisión de selección hacia $k = 2$, seguida de $k = 3$. El método del codo no tiene un punto de inflexión claramente definido, lo cual es común cuando los datos no presentan una estructura esférica bien definida. Conviene advertir que el elevado valor de la silueta para $k = 2$ se debe en parte a la concentración de valores iguales a cero en las variables de contracargo, lo que genera un grupo geoméricamente muy compacto.

4.1 Solución con tres grupos

La partición en tres grupos permite hacer una interpretación clara de la situación, esto a pesar de no haberse utilizado la etiqueta de fraude en su construcción. En la siguiente tabla se muestran los grupos generados.

Tabla 6. Centroides en las unidades originales para $k=3$.

Grupo	Avg.amount_d ay	Transaction_a mount	Is_declined	Declines_day	isForeignTran saction	isHighRiskCo untry	Chbk_day_amt	Chbk_6m_amt	Chbk_6m_freq	n	% fraude
0	507.36	7864.53	0.00	0.56	0.10	0.00	1.82	1.02	0.01	2630	2.8
1	586.09	19925.0	0.24	1.67	0.32	0.14	806.2	585.29	5.72	205	67.3
2	538.29	23339.92	0.01	4.69	0.95	0.74	5.59	1.69	0.03	240	98.3

Estos resultados permiten deducir:

- En el grupo 0 se tienen operaciones normales con importes moderados (7865 de media), ausencia práctica de rechazos y contracargos, y actividad mayoritariamente nacional.
- En el grupo 1 se concentran los comercios con historial de contracargos, con un promedio diario de 806 y 5,7 contracargos por semestre. Presenta la mayor tasa de rechazo directo (24%) y un perfil de riesgo acumulado.
- En el grupo 2 se registran operaciones internacionales (95%), con países de alto riesgo (74%), con más rechazos diarios (4,7) e importes elevados (23340), pero sin historial de contracargos.

Los grupos y sus descripciones evidencian que los grupos 1 y 2 corresponden a dos mecanismos de fraude diferenciados. En el primer caso, grupo 1, se concentra en los comercios con problemas repetitivos que tienen revisión de cobros; mientras que, en el segundo caso, grupo 2, presenta un

patrón de fraude con tarjetas comprometidas (intentos repetidos, importes altos, origen internacional y sin historial previo). Lo interesante de este resultado es que se han generado los grupos como un método no supervisado, lo que permite notar que los datos utilizados representan la estructura de un fenómeno real. Asignando interpretativamente los grupos 1 y 2 a la categoría de alerta, la partición puede evaluarse como detector binario con *recall* de 0,835 y precisión de 0,840, lo que demuestra un excelente resultado de agrupación para identificar los casos fraudulentos.

4.2 Solución con dos grupos

El agrupamiento con $k=2$, en comparación con $k=3$, aísla el grupo de comercios con historial de contracargos (206 registros, 67,5 % de fraude) y agrupa todo lo demás en un único conglomerado de 2.869 registros. En la siguiente tabla se presentan los centroides correspondientes a este caso. Bajo el mismo criterio utilizado previamente, asignando el grupo 0 a la categoría de alerta, el *recall* cae a 0,310 y la precisión a 0,675.

Tabla 7. Centroides en las unidades originales para $k=2$.

Grupos	Avg_amount_ day	Transaction_ amount	Is_declined	Declines_day	isForeignTra nsaction	isHighRiskC ountry	Chbk_day_a mt	Chbk_6m_am t	Chbk_6m_fre q	n	% fraude
0	586.15	19908.64	0.24	1.66	0.33	0.15	805.05	583.48	5.71	206	67.50
1	509.92	9156.06	0.00	0.91	0.22	0.06	1.94	1.00	0.01	2869	10.80

La simplificación generada por $k=2$, como se ve en la siguiente tabla de correspondencia entre las dos soluciones, hace que el grupo de fraude transfronterizo (98.3% de fraude) quede absorbido en el grupo mayoritario. Esto hace que 309 de los 448 fraudes (69% del total) se diluyan en un grupo que se interpretaría como una operación normal, de ahí la caída en el *recall* y la precisión.

Tabla 8. Correspondencia entre ambas soluciones.

	Cluster $k=2$	
Cluster $k=3$	0	1
0	0	2630
1	204	1
2	2	238

4.3 Ventajas y desventajas de la técnica de agrupamiento

Como ventajas se tienen:

- Eficiencia computacional.
- Interpretación directa de los centroides en las unidades de la situación.
- No se requieren etiquetas (aplicable cuando el fraude aún no está confirmado).

- Identificación de diferentes mecanismos de fraude.

Como desventajas se tienen las siguientes:

- La exigencia de fijar previamente el número de grupos.
- La suposición de agrupaciones de forma esférica y tamaño similar (no aplicable a variables binarias).
- Es sensible a la escala (verificable al comparar el resultado de este informe con los datos proporcionados en la guía de la actividad).
- Es sensible a la inicialización aleatoria.

5. Detección de anomalías

Para la detección de anomalías se siguen seis pasos, los cuales se describen a continuación:

1. Partición del conjunto de datos: los casos anómalos se reservan para los conjuntos de validación y de prueba, donde sirven para calibrar el umbral y medir el rendimiento. Para este caso, 1.576 transacciones legítimas se utilizan para entrenar, mientras que 749 sirven para validación y 750 para prueba, incluyendo 224 fraudes en cada uno de los dos últimos grupos.
2. Selección y transformación de variables: su elección depende de qué tan buenos indicadores del comportamiento anómalo sean, es decir, valores inusualmente altos o bajos respecto al patrón habitual. Se seleccionaron cuatro variables (Avg_amount_day, Transaction_amount, Declines_day, Chbk_6m_freq), excluyendo las dicotómicas, porque un modelo basado en la distribución normal carece de sentido para variables de dos valores, y dos de las tres variables de contracargo por la redundancia ya diagnosticada. Dado que los datos originales no cumplen el supuesto de normalidad (la asimetría oscila entre 2,11 y 4,05). Se aplicaron transformaciones de raíz cuadrada y logarítmica para aproximar esa condición, aunque la corrección resulta parcial en las variables con exceso de ceros.

Tabla 9. Resultado de la transformación de datos.

	Asimetría original	Asimetría transformada
Avg_amount_day	0,18	0,18
Transaction_amount	2,11	0,48
Declines_day	2,69	1,75
Chbk_6m_freq	4,05	3,64

3. Ajuste de parámetros: para cada variable se estiman su media y su varianza sobre el conjunto de entrenamiento.

Tabla 10. Parámetros de la variables seleccionadas.

	μ	σ^2
Avg_amount_day	515.4320	82211.5610
Transaction_amount	76.6480	1727.1300
Declines_day	0.2020	0.2610
Chbk_6m_freq	0.0420	0.0670

4. Cálculo de la probabilidad conjunta: asumiendo una distribución normal y la independencia entre variables, la probabilidad de que una observación sea normal es el producto de las probabilidades individuales de cada variable.
5. Definición del umbral: una observación se clasifica como anómala si su probabilidad cae por debajo de dicho umbral. Este valor se selecciona sobre el conjunto de validación maximizando el F1, métrica apropiada dado el desbalance entre clases.
6. Evaluación: se mide el rendimiento final sobre el conjunto de prueba, que no intervino en ninguna decisión previa. La evaluación se hace utilizando los modelos Gaussiano y *Isolation Forest* (Liu et al., 2008).

Tabla 11. Comparación de los métodos de detección de anomalías.

Métrica	Modelo gaussiano	Isolation Forest	Diferencia
Precisión	0,760	0,781	+0,021
Recall	0,848	0,973	+0,125
F1	0,802	0,867	+0,065
Falsos negativos	34	6	-28
Falsos positivos	60	61	+1

Los dos métodos identifican el fraude con alto rendimiento sin utilizar la etiqueta correspondiente durante el entrenamiento. *Isolation Forest* resulta claramente superior en *recall*, dejando por fuera únicamente 6 fraudes de 224, frente a los 34 del modelo gaussiano. Esto se explica desde los supuestos que están asociados a cada método: mientras que el estimador gaussiano asume independencia entre variables y una distribución normal (condiciones que este conjunto no satisface), *Isolation Forest* se basa en cortes aleatorios, sin imponer ninguna distribución, y captura interacciones entre variables.

6. Protocolo experimental de la parte 2 de la actividad

Se emplean nueve variables predictoras, excluyendo la variable objetivo, el identificador del comercio y las etiquetas de grupo generadas durante el agrupamiento. La partición reserva el 20% de los datos para la evaluación final, siendo 2.460 registros de entrenamiento con 358 fraudes y 615 de prueba con 90 fraudes.

Para prevenir la fuga de información, el escalador se ajusta únicamente con los datos de entrenamiento para después ser aplicado al conjunto de prueba. Si se calcula la media y la desviación sobre la totalidad de los datos, se constituiría una fuga de información. En este caso, el modelo incorporaría indirectamente estadísticos del conjunto sobre el que luego se evalúa, llevando a la producción de métricas optimistas que no se reproducirían en producción. Este tipo de error, denominado fuga de información, ha sido calificado como uno de los principales fallos metodológicos de la minería de datos (Kaufman et al., 2012) y se ha documentado empíricamente en diecisiete disciplinas científicas, donde ha dado lugar a conclusiones excesivamente optimistas (Kapoor y Narayanan, 2023).

La proporción entre transacciones legítimas y fraudulentas en el conjunto de entrenamiento es de 5,87 a 1, por lo que se adoptó un mecanismo que incrementa el coste asociado a los errores sobre la clase minoritaria durante el entrenamiento sin que se presente alteración de los datos (reponderación de clases). En términos prácticos, dejar pasar un fraude penaliza casi seis veces más que bloquear una operación legítima.

7. Laboratorio de regresión

Para la implementación del modelo de regresión se seleccionó como variable de respuesta el importe de la transacción (Transaction_amount). Esta es la única variable numérica continua con relevancia operativa porque, al anticipar el importe esperado, permite establecer límites de autorización y previsiones del riesgo. Considerando que se requiere una partición específica para este modelo, dado que el objetivo es continuo y no proviene de la estratificación por clase.

Se ajustaron tres modelos de regresión lineal con complejidad creciente: el primero incluye únicamente la variable Avg_amount_day, el segundo excluye la variable isFraudulent y el tercero es el modelo completo. Además, se aplicaron los modelos de árbol de regresión y regresión lineal con interacción. En la siguiente tabla se presentan las métricas para los modelos implementados.

Tabla 12. Modelos de regresión lineal

Modelo	MAE	RMSE	R ²	R ² entrenamiento
M1 - Solo promedio diario	5830,0	8352,3	0,3337	0,3474
M2 - Sin la variable de fraude	5237,4	7004,3	0,5314	0,5351
M3 - Modelo completo	5011,0	6406,1	0,6081	0,6144
M4 - Árbol de regresión	4544,3	6145,1	0,6393	—
M5 - Lineal con interacción	4448,2	5913,8	0,6660	—

7.1 Análisis de los resultados para las métricas

El error absoluto medio (MAE) del modelo completo indica que el modelo se equivoca en promedio en 5011 unidades monetarias por transacción. Si se compara con el importe medio de 9876, el MAE equivale al 50,7% del importe medio. Esto permite concluir que el modelo generado no se recomienda para su uso. La raíz del error medio cuadrático (RMSE) es superior al MAE en un 28%, cual se debe a que el RMSE amplifica los errores grandes al elevarlos al cuadrado antes de obtener

el promedio. Esta comparación permite identificar la presencia de un subconjunto de datos con desviaciones muy por encima de la media. El coeficiente de determinación (R^2) indica que el modelo explica el 60,8% de la variabilidad del importe, siendo importante resaltar que el valor obtenido durante el entrenamiento (0,6144) permite descartar un sobreajuste del modelo. En cuanto al 39% restante, corresponde a la variabilidad no capturada por las variables disponibles.

7.2 Interpretación de los coeficientes para el modelo completo

Según los datos de la tabla anterior, el promedio diario explica el 33% de la varianza, mientras que la inclusión de variables de comportamiento eleva el R^2 al 53%. La incorporación de la variable de fraude incrementa el R^2 hasta el 61 %. El coeficiente asociado al fraude (+14.742) predomina en el modelo al mantener constantes las demás variables; una transacción fraudulenta presenta un importe esperado casi 15.000 unidades superior. Este resultado es consistente con el análisis descriptivo presentado previamente en este informe, en el que el importe medio de las transacciones fraudulentas casi triplica al de las operaciones legítimas. Cabe destacar que los coeficientes de las dos variables de contracargo presentan signos opuestos (-7,78 y +9,89) a pesar de medir el mismo fenómeno. Este comportamiento ilustra un caso típico de inestabilidad inducida por la multicolinealidad. Cuando dos variables presentan una correlación del 95%, la distribución del efecto entre ellas es arbitraria y sus signos carecen de interpretación causal.

Tabla 13. Coeficientes para el modelo de regresión completo

Variable	Coeficiente
isFraudulent	14742,4700
Is_declined	-1254,4500
isHighRiskCountry	-1009,6900
isForeignTransaction	543,3500
Chbk_6m_freq	379,7700
Declines_day	-60,3300
Avg_amount_day	20,0600
Chbk_6m_amt	9,8900
Chbk_day_amt	-7,7800
Intercepto	-2655,45

7.3 Análisis de residuos y limitaciones

El análisis de los residuos revela tres deficiencias que hacen inviable el uso del modelo lineal para uso práctico (ver imagen 5).

- Predicciones imposibles: el modelo genera 62 predicciones de importe negativo, correspondientes al 10,1 % del conjunto de prueba. Este valor negativo no tiene sentido.
- Varianza no constante: la correlación entre la magnitud del residuo y la predicción alcanza 0,562, lo que se interpreta como que el error crece sistemáticamente con el valor estimado

(forma de abanico en la figura). Siendo esto evidencia del incumplimiento del supuesto de homocedasticidad, el cual es un requisito para la validez de la inferencia sobre los coeficientes.

- Estructura multiplicativa frente a especificación aditiva: esta es la limitación de fondo. Previamente en este informe se estableció que el importe es un múltiplo entero del promedio diario. Siendo esta una relación multiplicativa, mientras que la regresión lineal solo puede modelar efectos aditivos.




Imagen 5. Gráfico de análisis de residuos.

8. Naive Bayes

El clasificador Naive Bayes se basa en el teorema de Bayes para estimar la probabilidad de que una transacción sea fraudulenta a partir de sus características. Debido a que el cálculo exacto del teorema de Bayes resultaría computacionalmente inabordable, el algoritmo introduce, como simplificación, la suposición de que las variables son independientes entre sí una vez conocidas. Sabiendo que esta suposición es poco realista en la mayoría de los casos, es la que le otorga el calificativo de «ingenuo». Para las variables numéricas se plantean dos alternativas: la primera, discretizarlas en intervalos, y la segunda, modelarlas mediante una distribución continua. Para este caso, se eligió la variante gaussiana, que estima la media y la varianza de cada variable dentro de cada clase. Esta opción se prefirió sobre la discretización, ya que el material señala que la discretización es más adecuada para conjuntos de datos pequeños, mientras que en este estudio se dispone de 2.460 registros. Además, la definición de puntos de corte implicaría una decisión arbitraria adicional.

8.1 Matriz de confusión y curva ROC

La matriz de confusión, que se presenta en la siguiente tabla, cruza lo que ocurrió en la realidad con lo que el modelo predijo.

Tabla 14. Matriz de confusión del clasificador Naive Bayes

	Predicho: legítima	Predicho: fraude
Real: legítima	506 (verdaderos negativos)	19 (falsos positivos)
Real: fraude	11 (falsos negativos)	79 (verdaderos positivos)

El modelo identifica correctamente 506 transacciones legítimas y 79 fraudes. Los 19 falsos positivos representan operaciones legítimas bloqueadas, que se supone que generan molestia al cliente, coste de atención y riesgo reputacional, pero son recuperables mediante revisión manual. Los 11 falsos negativos son fraudes que el sistema deja pasar y constituyen el error crítico, porque cada uno implica una pérdida financiera, dado que el importe medio de una operación fraudulenta asciende a 22.855 unidades.

La curva ROC relaciona la proporción de fraudes detectados con la proporción de falsas alarmas a lo largo de todos los posibles umbrales de decisión. El área bajo esa curva resume el resultado en un único número entre 0,5 y 1.




Imagen 6. Curva ROC

El valor de AUC mostrado en la imagen anterior indica que si se selecciona aleatoriamente una transacción fraudulenta y una legítima, el modelo asigna una mayor probabilidad de fraude a la primera en el 97,7 % de los casos. Por lo tanto, la capacidad del modelo para ordenar las transacciones según el riesgo es considerablemente superior a lo que sugiere el valor F1 de 0,840. El margen de mejora se encuentra principalmente en la elección del umbral para declarar fraude, más que en el algoritmo. Es recomendable comparar este valor con el PR-AUC, que es sensiblemente inferior (0,8287). En situaciones de desbalance de clases la curva ROC tiende a ofrecer un resultado más favorable porque la tasa de falsas alarmas se calcula sobre una clase mayoritaria muy numerosa. En este escenario, la curva precisión-recall proporciona una evaluación más exigente e informativa (Saito y Rehmsmeier, 2015).

8.2 Análisis del supuesto de independencia del método

El nombre del método proviene de un supuesto que no se cumple en este conjunto. Las variables de contracargo tienen correlaciones de hasta 0,954 entre sí, y la variable de transacción internacional tiene una correlación de 0,490 con el país de alto riesgo. Al multiplicar las probabilidades de variables redundantes, el modelo cuenta varias veces la misma evidencia, lo que lleva a estimaciones demasiado confiadas.

La verificación empírica confirma lo anterior, porque al eliminar dos de las tres variables de contracargo, el AUC aumenta de 0,9774 a 0,9818, a pesar de contar con menos información. Sin embargo, se mantiene el modelo completo para garantizar la comparabilidad con los otros algoritmos usando el mismo conjunto de predictores.

8.3 Algunas reflexiones sobre los sesgos del algoritmo y las implicaciones éticas

A partir de los resultados del modelo y la comprensión de la situación y los datos, se pueden deducir dos implicaciones éticas relacionadas con el sesgo asociado con el origen geográfico y el sesgo asociado con la clasificación de transacciones y asignación como legítimas o fraudulentas.

La variable que indica si un país es de alto riesgo presenta la correlación más significativa con el fraude en el conjunto de datos. Un análisis detallado revela una relación casi determinista: de las 205 transacciones originadas en estos países, 203 resultan fraudulentas y solo 2 son legítimas. Cualquier modelo que sea entrenado con estos datos aprenderá a rechazar casi todas las operaciones provenientes de esos orígenes. Sin embargo, surge un problema ético porque esta variable no refleja la conducta del titular, sino su procedencia. Automatizar este tipo de decisiones conlleva el supuesto de que ciertos orígenes presentan una probabilidad de rechazo cercana al 100%, sin considerar el comportamiento individual de cada uno. Los dos clientes legítimos de ese grupo serían bloqueados de manera sistemática y sin posibilidad de recurso alguno. Este fenómeno constituye un ejemplo de discriminación mediante una variable sustituta (proxy), es decir, un atributo técnico que actúa como sustituto de una característica protegida. Una situación similar se observa en la variable de transacción internacional, presente en 706 registros con una tasa de fraude del 45,5%. En este caso, la penalización afectaría a un grupo mucho más amplio, como migrantes, viajeros y trabajadores transfronterizos, en el que más de la mitad son clientes legítimos.

La variable objetivo no está exenta de errores porque la etiqueta «fraude» se asigna a partir de decisiones humanas previas, por ejemplo, alertas generadas por reglas existentes, reclamaciones tramitadas y contracargos aceptados. Si los mecanismos de asignación previos prestaban una mayor atención a las operaciones internacionales, esas transacciones tenían más posibilidades de ser identificadas y etiquetadas, mientras que, en el otro caso, el fraude doméstico permanecía en gran medida invisible. El modelo no aprende dónde ocurre realmente el fraude, sino dónde se detectó anteriormente. Al implementarse, enfoca la vigilancia en los mismos grupos y crea un ciclo de retroalimentación que refuerza sus propias premisas. Un dato claro es que 245 de los 448 fraudes, un 55%, no provienen de países de alto riesgo. Un sistema que limite su detección al origen geográfico ignoraría la mayoría de los casos.

9. Interpretabilidad y explicabilidad

Los árboles de decisión segmentan el espacio de variables mediante preguntas sucesivas. Para decidir cada corte, emplean medidas de pureza como la entropía o el índice de Gini, que cuantifican el grado de mezcla entre clases en cada nodo. Se compararon cinco profundidades y el resultado muestra una aparente paradoja que conviene explicar (ver siguiente tabla).

Tabla 15. Efecto de la profundidad del árbol sobre el rendimiento

Modelo	Hojas	Precision	Recall	F1	ROC-AUC	FN	FP
Profundidad 3	8	0.7788	0.9000	0.8351	0.9811	9	23
Profundidad 4	13	0.6846	0.9889	0.8091	0.9900	1	41
Profundidad 6	31	0.8737	0.9222	0.8973	0.9633	7	12
Profundidad 8	56	0.9101	0.9000	0.9050	0.9432	9	8
Profundidad None	60	0.9205	0.9000	0.9101	0.9433	9	7

Como se evidencia en la tabla, el valor para F1 aumenta al incrementar la profundidad del árbol; sin embargo, el AUC disminuye porque ambas métricas capturan aspectos diferentes. Un árbol más profundo produce hojas muy puras con pocas observaciones (lo que hace que sus probabilidades se saturen en valores cercanos a 0 o 1) y clasifica correctamente en el umbral estándar, pero pierde capacidad para ordenar las transacciones por riesgo, que es justamente lo que evalúa el AUC. Esto refleja el sobreajuste, que se reduce mediante la poda.

Se decide seleccionar el árbol de profundidad 4 porque obtiene el mejor AUC, reduce los falsos negativos a uno solo y con 13 hojas mantiene una estructura legible, requisito indispensable para el objetivo de interpretabilidad. El coste de tomar esta decisión está en los 41 falsos positivos.

9.1 Estructura del árbol




Imagen 7. Árbol de decisión (profundidad 4, criterio GINI)

Para la primera ramificación se utiliza la variable relacionada con la transacción internacional. Siguiendo esta rama, se subdivide posteriormente utilizando la variable para identificar al país de

alto riesgo. En este punto, la tercera ramificación, cuando el modelo identifica una transacción internacional que procede de un país de alto riesgo y que, además, tiene un promedio inferior a 1350 se identifica como fraude. Por otro lado, la rama con transacciones nacionales clasifica utilizando el historial de sobrecargos y el número de rechazos. Esta estructura permite reproducir los dos mecanismos de fraude previamente identificados en el numeral 5.1 de este informe (Clasificación k-Means con tres grupos), relacionados con los ataques relacionados con operaciones internacionales con el historial de contracargos. En este punto del análisis se identifica la convergencia a una misma conclusión utilizando un método no supervisado y otro supervisado, lo cual permite darle más solidez al análisis presentado.

9.2 Aplicación de SHAP e influencia de las variables

Se tomó la decisión de selección SHAP (Lundberg y Lee, 2017) sobre LIME porque, (1) para los modelos que se basan en árboles, SHAP calcula los valores de Shapley de forma exacta mientras que en el caso de LIME, este estima una aproximación local mediante un muestreo aleatorio, introduciendo variabilidad entre las ejecuciones. Además, (2) SHAP asegura que la suma de las contribuciones de todas las variables reproduzca exactamente la predicción del modelo.

Tabla 16. Contraste entre dos medidas de importancia de las variables

Variable	Importancia Gini	Rango	SHAP (media)	Rango
isForeignTransaction	0,3676	1	0,2143	1
6-month_chbk_freq	0,2401	2	0,1105	2
Total Number of declines/day	0,2066	3	0,0823	3
isHighRiskCountry	0,0622	5	0,0808	4
Transaction_amount	0,0876	4	0,0796	5
Average Amount/transaction/day	0,0312	6	0,0330	6
Is declined	0,0047	7	0,0047	7
Daily_chargeback_avg_amt	0,0000	8	0,0000	8
6_month_avg_chbk_amt	0,0000	9	0,0000	9

Al hacer la lectura de la anterior tabla, en la que se presentan los valores de importancia de SHAP y de GINI, se identifican cuatro variables con predominio según SHAP:

- La transacción internacional es la variable dominante sobre la toma de decisiones con una contribución media que es casi el doble de la siguiente variable (6-month_chbk_freq). Al encontrarse una transacción internacional, se lleva la predicción hacia el fraude con mayor intensidad, mientras que, por el otro lado, las transacciones nacionales conllevan un desplazamiento contrario de menor magnitud.
- La frecuencia de sobrecargos aporta desde un criterio relacionado con el historial de las transacciones, siendo un efecto acumulativo y creciente. A medida que se tengan más contracargos en un periodo de seis meses, mayor será la contribución hacia la clasificación como transacción fraudulenta.

- El número de rechazos diarios nos muestra el patrón de los intentos repetidos, que son característicos de la evidencia de tarjetas comprometidas. El modelo ubica el umbral alrededor de 6,5 rechazos.
- El país de alto riesgo refuerza la variable relacionada con la transacción internacional, teniendo un efecto determinante en la toma de decisiones cuando está presente.
- El importe de la transacción resultó tener un efecto menos influyente del que se identificó en el análisis descriptivo de los datos. Al analizar la situación se identifica que este valor ya está inmerso en las anteriores variables y el modelo hace una discriminación a partir del contexto de dicha transacción.
- Las dos variables de sobrecargo por importe no tienen valoración de importancia, lo cual es una confirmación de lo ya encontrado en el análisis exploratorio sobre la multicolinealidad de variables.

Ahora, al revisar la tabla, se encuentra una diferencia entre la importancia asignada por SHAP y GINI. Esta diferencia se debe a la forma de funcionamiento de cada uno. Mientras que GINI cuantifica la reducción de la mezcla acumulada en los nodos donde se utiliza la variable, ponderada por el número de observaciones que atraviesan el nodo (favoreciendo a las variables en la raíz), SHAP promedia la contribución real de la variable a cada predicción individual, reflejando el efecto de esta en la rama en la que efectivamente actúa.

10. Random Forest y flujo de MLOps

Para este modelo se emplean la combinación de un grupo de árboles de decisión utilizando como fuentes de diversidad el remuestreo, en el que cada árbol se entrena con una muestra extraída del conjunto original (en promedio dos tercios de las observaciones), y la selección aleatoria de variables, evaluando un subconjunto de predictores en cada corte. La predicción final se genera como un resultado del voto mayoritario del grupo de árboles.

Para la selección del número de árboles se tiene en cuenta el error *out-of-bag*, que utiliza el tercio de observaciones no empleado en cada árbol para estimar el error (ver siguiente imagen). A partir de 200 árboles, el error se mantiene relativamente constante; por lo tanto, se seleccionaron 200 árboles para evitar un coste computacional mayor sin una ganancia importante.




Imagen 8. Evolución del error *out-of-bag*.

Con el modelo final se obtiene una precisión de 0,9659, un recall de 0,9444 y un F1 de 0,9551 (ver la tabla de matriz de confusión). En comparación con el árbol individual, se tiene una mejoría en todas las métricas, pasando el F1 de 0,809 a 0,955 y los falsos positivos caen de 41 a 3. La estimación *out-of-bag* (0,9833) es muy parecida a la estimada en el conjunto de prueba independiente (0,9870), lo que es una validación de su utilidad como estimador del error de generalización.

Tabla 17. Matriz de confusión Random Forest

	Predicho: legítima	Predicho: fraude
Real: legítima	551 (verdaderos negativos)	4 (falsos positivos)
Real: fraude	3 (falsos negativos)	87 (verdaderos positivos)

Se presentan cinco etapas para llevar el modelo entrenado a un entorno productivo.:

- Serialización: en este primer paso se guarda el modelo entrenado de tal forma que sea recuperable posteriormente. (Implementado en el Notebook anexo).
- Versionado: debe abarcar el código, mediante un sistema de control de versiones; los datos, dado que un modelo no es reproducible sin el conjunto exacto que lo originó; y los experimentos, registrando hiperparámetros, métricas y artefactos de cada ejecución. (Implementado en el Notebook anexo).
- Empaquetado y despliegue: el servicio se presenta a través de una interfaz de programación y se empaqueta en un contenedor que garantiza la reproducibilidad del entorno. (Implementado en el Notebook anexo).
- Monitorización: se vigilan los cambios en la distribución de las variables de entrada respecto a las del entrenamiento, mediante pruebas estadísticas de contraste de distribuciones; la degradación del *recall* una vez confirmadas las etiquetas reales, debe contemplarse el retardo de etiquetado; latencia de respuesta, disponibilidad del servicio y volumen de peticiones, y la tasa de falsos positivos desagregada por segmento geográfico.
- Reentrenamiento y reversión: reentrenamiento programado o disparado por umbral de degradación.

11.Boosting moderno y máquinas de vector soporte (SVM)

Para el desarrollo de este apartado se debe aclarar que durante el intento de implementación en Visual Studio Code, el entorno de ejecución no permitió cargar las bibliotecas XGBoost y LightGBM. Por lo anterior, se emplearon como reemplazo las dos implementaciones de gradient boosting incluidas en scikit-learn (Pedregosa et al., 2011). Una de ellas basada en la discretización de las variables en histogramas, inspirada directamente en LightGBM, y la otra correspondiente a la formulación clásica de Friedman (2001).

Los hiperparámetros se fijaron en 200 árboles secuenciales, una profundidad máxima de 4 y una tasa de aprendizaje de 0,1. El desbalance se trató mediante la reponderación de 5,87 descrita en el apartado 7, aplicada de forma uniforme a todos los modelos.

Las SVM, propuestas por Cortes y Vapnik (1995), son el primer modelo de predicción no basado en fundamentos probabilísticos. Alternativamente, se trata de un planteamiento geométrico que busca el hiperplano que mejor separa las clases en el espacio de características.

Se realizó un contraste directo entrenando el mismo modelo con y sin estandarización previa.

Tabla 18. Efecto de la estandarización sobre la SVM con núcleo radial

Configuración	Precisión	Recall	F1	ROC-AUC	Falsos negativos	Tiempo
Sin escalar	0,6577	0,8111	0,7264	0,9558	17	0,369 s
Escalado	0,9560	0,9667	0,9613	0,9968	3	0,068 s

Por ser un modelo geométrico, la SVM se apoya en la distancia entre observaciones y cuando las variables presentan escalas dispares, esa distancia queda dominada por las de mayor recorrido. En el caso de los datos de esta actividad, el importe abarca un rango de 108.000 unidades, mientras las variables dicotómicas recorren una sola. Entonces, sin estandarizar, el importe determina prácticamente toda la geometría del problema y las otras variables se vuelven invisibles para el algoritmo. El F1 cae de 0,961 a 0,726 y los falsos negativos se multiplican por más de cinco. Sumado a esto, el tiempo de entrenamiento se quintuplica, porque el optimizador necesita más iteraciones para converger sobre un espacio mal condicionado. La estandarización no es, por tanto, una recomendación en las SVM, sino que resulta más adecuado que sea un requisito previo.

Se evaluaron dos tipos de núcleo y cinco valores del parámetro de coste. El número de vectores de soporte permite verificar directamente el comportamiento teórico.

Tabla 19. Efecto del núcleo y del parámetro C sobre el rendimiento de la SVM (celda C62).

Configuración	Precisión	Recall	F1	FN	FP	Vectores de soporte
Lineal, C = 0,01	0,8969	0,9667	0,9305	3	10	—
Lineal, C = 0,1	0,9355	0,9667	0,9508	3	6	—
Lineal, C = 100	0,9255	0,9667	0,9457	3	7	—
Radial, C = 0,01	0,6992	0,9556	0,8075	4	37	1.065 (43,3 %)
Radial, C = 0,1	0,7928	0,9778	0,8756	2	23	445 (18,1 %)
Radial, C = 1	0,9255	0,9667	0,9457	3	7	246 (10,0 %)
Radial, C = 10	0,9560	0,9667	0,9613	3	4	164 (6,7 %)
Radial, C = 100	0,9451	0,9556	0,9503	4	5	124 (5,0 %)

Con C = 0,01 el modelo usa 1.065 observaciones, un 43,3% del conjunto de entrenamiento, mientras que con C = 100 se reduce a 124, que corresponde a un 5,0% de los datos. Un margen amplio incluye más observaciones dentro de la banda de separación y son esas las que definen el hiperplano. El rendimiento muestra una curva en forma de U invertida que

refleja el equilibrio entre sesgo y variabilidad. Con $C = 0,01$ el margen es demasiado permisivo y el modelo no alcanza el objetivo, con 37 falsos positivos. Al aumentar C , la frontera se ajusta más a los datos y el error baja hasta el óptimo en $C = 10$. Con $C = 100$ el rendimiento baja un poco, lo que indica que empieza a haber sobreajuste. Es importante que el óptimo no esté en ningún extremo. Hay un punto intermedio que equilibra la tolerancia al error y el ajuste a los datos.

El núcleo lineal logra un F1 de 0,9508. El radial llega a 0,9613. Esto representa una mejora de solo 1,1 puntos porcentuales. La conclusión principal es que la frontera de decisión de este problema es casi lineal.

El núcleo de base radial permite obtener fronteras curvas al proyectar de forma implícita los datos a un espacio de mayor dimensión por medio del procedimiento conocido como kernel trick. Esto evita las expansiones polinómicas explícitas y su alto coste computacional. Pero esa capacidad extra encuentra aquí poca estructura útil. El resultado concuerda con lo que se encontró en el apartado 3.5. Si la separación depende sobre todo de un umbral en el cociente entre el importe y su promedio, la frontera subyacente es simple.

Cabe señalar además que el núcleo lineal mantiene un recall constante de 0,9667 para todos los valores de C . En cambio, el radial varía entre 0,9556 y 0,9778. El modelo lineal es mucho más estable frente a la elección del hiperparámetro. Esta propiedad es valiosa en un entorno productivo.

12. Comparación de los modelos

El análisis del error económico muestra que, en este conjunto, una transacción fraudulenta tiene un valor medio de 22.855 unidades monetarias. De los 90 fraudes en el conjunto de prueba, cada falso negativo representa una pérdida de ese tamaño. Naive Bayes tuvo 11 falsos negativos y la SVM radial solo 3, lo que supone una diferencia de unos 183.000 en pérdidas no detectadas en unas 615 transacciones. En la práctica, el impacto en el F1 es más importante que el modelo elegido. Recordando que un falso positivo puede causar molestias (bloqueo de una operación, requerimiento de verificación telefónica o insatisfacción del cliente), pero se puede recuperar y su coste es bajo, de tan solo decenas de unidades. Por el otro lado, un falso negativo se representa en una pérdida definitiva. La diferencia de costes puede ser hasta mil veces mayor, por lo que en este caso es mejor priorizar el recall antes que la precisión.

El árbol de decisión logra el mayor recall, con solo un falso negativo, pero tiene el peor F1 porque genera 41 falsos positivos. Si consideramos los costes asimétricos, podría ser la mejor opción, ya que detectar 3 fraudes más a cambio de 39 falsos positivos es ventajoso si el coste de un fraude es más de veinte veces el de una revisión manual. Sin embargo, esta decisión depende de una matriz de costes clara, que este conjunto de datos no incluye.

Todos los modelos se evaluaron con el umbral estándar de 0,5, El boosting tiene un AUC de 0,9986, lo que indica una clasificación casi perfecta. Por eso, la mejora posible está en ajustar mejor el umbral, no en cambiar el algoritmo.

Naive Bayes es el modelo más rápido porque solo necesita calcular medias y varianzas. Mientras que, las SVM también son muy eficientes, incluso más que el random forest y el boosting tradicional; además, cuanto más bajo es el parámetro C, más tiempo tarda en entrenar, ya que un margen más amplio requiere más vectores de soporte y hace que el problema de optimización sea más complejo.

Sin embargo, este orden de eficiencia cambia cuando se trabaja a gran escala porque las SVM tienen una complejidad computacional que puede ser cuadrática o cúbica según el número de datos. Con 2.460 registros se tiene un coste es bajo, pero si hay millones de transacciones al día, los métodos basados en árboles son mucho mejores. El boosting por histogramas está pensado para este tipo de situaciones y es cinco veces más rápido que el boosting tradicional, con un rendimiento similar, lo que anticipa buenos resultados en grandes volúmenes. Además, no fue necesario usar muestreo estratificado para entrenar las SVM porque el conjunto completo puede manejarse y el tiempo de entrenamiento es menor de un segundo en todas las pruebas.

Desde el punto de vista técnico, se recomienda usar gradient boosting porque tiene el mejor F1, el AUC más alto, menos falsos positivos y un rendimiento escalable en su versión por histogramas. La SVM con núcleo radial obtiene resultados similares y reduce los falsos negativos, pero su coste computacional aumenta significativamente a medida que aumenta el tamaño de los datos.

Tabla 20. Tabla comparativa de los modelos

Modelo	Precisión	Recall	F1	ROC-AUC	PR-AUC	FN	FP	Tiempo (s)
Gradient boosting clásico	0,9773	0,9556	0,9663	0,9986	0,9929	4	2	0,546
SVM radial (C = 10)	0,9560	0,9667	0,9613	0,9968	0,9787	3	4	0,069
Boosting por histogramas	0,9556	0,9556	0,9556	0,9985	0,9924	4	4	0,104
Random forest	0,9659	0,9444	0,9551	0,9913	0,9829	5	3	0,385
SVM lineal (C = 0,1)	0,9355	0,9667	0,9508	0,9972	0,9868	3	6	0,073
Naive Bayes	0,8061	0,8778	0,8404	0,9774	0,8287	11	19	0,002
Árbol de decisión	0,6846	0,9889	0,8091	0,9900	0,9404	1	41	0,005
Regla ratio > 30 (referencia)	0,9080	0,8778	0,8927	—	—	11	9	—

Tabla 22. Comparación de los modelos supervisados bajo idéntica partición y preprocesamiento (celda C64).

13.Integración, limitaciones y panorama actual

Entre los aspectos a resaltar en los resultados obtenidos está, en primer lugar, que el agrupamiento no supervisado permitió identificar dos mecanismos de fraude. Esta particularidad se identificó en los árboles de decisión, siendo una técnica supervisada. En segundo lugar, el análisis exploratorio detectó una correlación de 0,998 entre las variables de contracargo. Al respecto, el árbol de decisión les asignó valores de importancia cero, Naive Bayes mejoró su AUC al no considerarlas; y la

regresión lineal produjo coeficientes de signo opuesto por ser variables que miden lo mismo. Cuatro evidencias independientes del mismo diagnóstico.

En la siguiente tabla se resumen las ventajas y desventajas identificadas para cada técnica utilizada en este informe.

Modelo	Ventajas	Desventajas
K-means	Centroides interpretables; no requiere etiquetas; identificó dos mecanismos de fraude.	Exige fijar k; supone grupos esféricos; distancia cuestionable sobre variables binarias.
Modelo gaussiano	Formulación transparente; umbral calibrable; requiere pocos datos.	Supone normalidad e independencia, ambas incumplidas; 34 falsos negativos.
Isolation Forest	Sin supuestos distribucionales; mejor recall no supervisado.	El umbral requiere calibración externa; menos interpretable.
Regresión lineal	Coeficientes interpretables; sin sobreajuste.	Predicciones negativas imposibles; varianza no constante; incapaz de modelar estructura multiplicativa.
Naive Bayes	Entrenamiento tres órdenes de magnitud más rápido; salida probabilística.	Supuesto de independencia violado; el peor recall de los supervisados.
Árbol de decisión	Estructura auditable regla por regla; mejor recall global.	41 falsos positivos; alta variabilidad; sensible a la profundidad.
Random forest	Estimación de error gratuita; robusto; pocos hiperparámetros críticos.	Pérdida de interpretabilidad; reparte la importancia entre variables correlacionadas.
Boosting	Mejor F1 y AUC; escalable en su variante por histogramas.	Más hiperparámetros; naturaleza secuencial no paralelizable.
SVM	Buen recall; el núcleo lineal es muy estable frente a C.	Escalado obligatorio; complejidad cuadrática o cúbica en el número de observaciones.

El trabajo realizado permite evidenciar que las técnicas se aplican correctamente, que sus supuestos se verifican y que sus resultados se interpretan en el contexto de la problemática supuesta con el *dataset*. Sin embargo, con lo discutido hasta ahora, lo que no puede demostrar es la superioridad de los modelos complejos sobre reglas simples, porque el conjunto de datos no ofrece la complejidad necesaria para establecer esa diferencia (algunas conclusiones se obtuvieron de análisis exploratorio de los datos). En un escenario real, por ejemplo, la comparación podría arrojar resultados muy distintos y previsiblemente mucho más favorables a los conjuntos de árboles.

Se identificaron las siguientes limitaciones:

- El carácter sintético del *dataset*, ya argumentado en el apartado durante el informe.
- La variable de fecha está vacía en los 3.075 registros, lo que impide la validación temporal, lo que aportaría información adicional para la correcta detección de fraude.
- La muestra resulta reducida (3.075 registros) si se compara con los volúmenes habituales del dominio, que se miden en millones de transacciones a analizar.

- El desbalance del 14,6 % resulta ser dos órdenes de magnitud por encima del observado en datos reales.
- Cada fila representa una transacción de comercio, lo que impide modelar patrones de comportamiento por cliente.
- Restricción del entorno de ejecución que impidió emplear XGBoost y LightGBM, sustituidos por implementaciones equivalentes.

Los modelos clásicos utilizados en este estudio siguen siendo relevantes en el campo del fraude, donde son considerados estándar por tres motivos: los datos tabulares aún prefieren los conjuntos de árboles sobre las redes neuronales, los requisitos regulatorios de explicabilidad favorecen modelos transparentes, y la necesidad de decisiones rápidas en milisegundos limita las arquitecturas demasiado grandes. Sin embargo, el sector ha avanzado hacia nuevas direcciones que este trabajo puede anticipar: las redes neuronales sobre grafos identifican el fraude como una red de relaciones, detectando anillos de comercios y tarjetas ligados que un análisis individual no puede captar; los modelos secuenciales aprovechan el historial completo de transacciones, que es la dimensión ausente en este conjunto; el aprendizaje federado permite entrenar modelos entre diferentes entidades sin compartir datos de clientes; y la detección automática de deriva se ha vuelto esencial en un entorno adversarial. La inteligencia artificial generativa tiene un impacto dual en este ámbito. Por un lado, los grandes modelos de lenguaje ayudan a redactar explicaciones comprensibles para alertas dirigidas a analistas y clientes —cumpliendo con la exigencia de explicabilidad— y a generar datos sintéticos que refuerzan conjuntos con categorías minoritarias escasas. Por otro lado, facilitan la producción masiva de ingeniería social personalizada, la creación de identidades falsas, y la clonación de voz en fraudes telefónicos, desplazando parte del problema desde la transacción hacia la verificación de identidad. Además, existe una conexión directa con este trabajo: el conjunto analizado es un ejemplo de datos sintéticos. Su análisis evidencia claramente el riesgo de esta práctica —los patrones artificiales pueden ser mucho más simples que los reales—, sirviendo como advertencia sobre el uso de la generación sintética como sustituto de datos genuinos.

14. Anexo

Este informe se complementa con el código en el que se han implementado los modelos presentados. Se puede acceder a un archivo de Jupyter Notebook a través del siguiente enlace:

- https://github.com/omardaza81/Aprendizaje_Automatico_Fraudes.git

También se entrega este anexo como archivo comprimido en la plataforma Campus Virtual de UNIR.

15. Referencias bibliográficas

Dal Pozzolo, A., Caelen, O., Johnson, R. A. y Bontempi, G. (2015). Calibrating probability with undersampling for unbalanced classification. IEEE Symposium Series on Computational Intelligence, 159–166. <https://doi.org/10.1109/SSCI.2015.33>

- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An introduction to statistical learning with applications in R* (2.^a ed.). Springer. <https://www.statlearning.com>
- Kapoor, S. y Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804. <https://doi.org/10.1016/j.patter.2023.100804>
- Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), artículo 15. <https://doi.org/10.1145/2382577.2382579>
- Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774. <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>
- Liu, F. T., Ting, K. M. y Zhou, Z.-H. (2008). Isolation forest. *Eighth IEEE International Conference on Data Mining*, 413–422. <https://doi.org/10.1109/ICDM.2008.17>
- Newsom, J. (2025). Measures of association for contingency tables [Material docente, Psy 525/625 Categorical Data Analysis]. Portland State University. https://web.pdx.edu/~newsomj/cda/class/ho_phi.pdf
- Saito, T. y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>